

# **Proiect Matematici financiare Criptomonedă**

**-Analiza evoluției Dogecoin  
pe baza datelor Yahoo  
Finance-**

# 1. Introducere

*Întrebarea la care ne propunem să răspundem este: Pot modelele financiare clasice (CAPM și Fama-French cu 3 factori) să explice comportamentul randamentelor Dogecoin într-o perioadă recentă post-pandemie?*

Lucrarea de față își propune să analizeze evoluția și randamentele Dogecoin, una dintre cele mai cunoscute criptomonede, utilizând modele financiare consacrate precum CAPM și modelul Fama-French cu 3 factori. Analiza se bazează pe date istorice preluate de pe platforma Yahoo Finance, ceea ce permite o abordare practică și actualizată asupra comportamentului pieței crypto.

## 1.1. Istoric si inceputurile Dogecoin

Dogecoin, lansat inițial ca o glumă în 2013, a cunoscut o ascensiune spectaculoasă, în mare parte datorită comunității puternice și sprijinului vocal al unor personalități precum Elon Musk. Deși inițial valoarea sa era neglijabilă, începând cu 2021, Dogecoin a început să atragă atenția investitorilor, ajungând să fie listat pe marile burse și acceptat de unele companii în tranzacții.

## 1.2. Modelele CAPM și Fama-French

Pentru că piața criptomonedelor este foarte volatilă, e important să analizăm serios cum se comportă aceste active și dacă putem prezice evoluția lor folosind metode financiare clasice. În această lucrare, folosim și comparăm două modele cunoscute:

- **Modelul CAPM**, care spune că randamentul unei monede (cum e Dogecoin) depinde de cum merge piața în general și cât de riscantă este moneda față de piață;
- **Modelul Fama-French cu 3 factori**, care pornește de la CAPM, dar adaugă și alți doi factori: unul legat de mărimea companiilor și unul legat de cât de "ieftine" sau "scumpe" sunt acestea.

Folosim aceste modele ca să vedem cât de bine pot explica ele schimbările de preț ale Dogecoin și să calculăm ce randamente ne-am putea aștepta să obținem lunar și anual. În acest fel, încercăm să arătăm că și criptomonedele pot fi analizate cu metodele folosite de obicei pentru acțiuni și alte active financiare.

### 1.3. Yahoo Finance

**Yahoo Finance** este un site foarte cunoscut care oferă informații despre piețele financiare. A fost lansat în anul **1997** de compania Yahoo și de atunci a devenit una dintre cele mai folosite surse pentru date despre acțiuni, indici bursieri, mărfuri și, mai nou, **criptomonedele**.

Platforma le oferă utilizatorilor date despre prețurile activelor, știri financiare și grafice. Un mare avantaj este că putem găsi **date istorice** (zilnice, lunare, anuale) pe care le putem folosi ușor în analize. De exemplu, putem urmări cum a evoluat prețul Dogecoin în ultimele luni și să vedem ce randamente a avut. Aceste date pot fi descărcate sau preluate direct în cod folosind librăria `yfinance` din Python.

Yahoo Finance este foarte util pentru că ne dă acces la o cantitate mare de informații gratuite, bine organizate și actualizate în timp real. Asta ne ajută să facem analize proprii, să comparăm diferite monede și să testăm modele financiare.

Într-o piață ca cea a criptomonedelor, unde lucrurile se schimbă rapid și apar mereu monede noi, o sursă de date clară și ușor de folosit, cum este Yahoo Finance, devine foarte importantă pentru oricine vrea să înțeleagă mai bine cum funcționează această lume.

## 2. Date inițiale și metode de prelucrare

Lucrarea analizează fluctuațiile lunare ale criptomonedei **Dogecoin (DOGE)**, exprimată în **USD (dolar american)**, pe o perioadă de 6 luni, între **septembrie 2024 și martie 2025**. Scopul este de a înțelege comportamentul acestei monede în timp și de a vedea dacă se poate estima randamentul viitor folosind modele financiare clasice.

```
# === 1. Setări inițiale ===
ticker = 'DOGE-USD'
start = "2024-09-01"
end = "2025-03-01"

# === 2. Descarcă datele DOGE ===
doge_data = yf.download(ticker, start=start, end=end)[['Close']].dropna()
doge_data.index = pd.to_datetime(doge_data.index)
```

Pentru modelul **CAPM**, s-a presupus un randament mediu fără risc (RF) și o primă de risc de piață (Mkt-RF). Apoi, s-a aplicat o regresie liniară simplă pentru a estima **beta-ul** Dogecoin, adică cât de sensibil este DOGE față de mișcările pieței:

```
# === 6. CAPM ===
rf = ff_data['RF'].mean()
market_premium = ff_data['Mkt-RF'].mean()
X_capm = sm.add_constant(ff_data['Mkt-RF'])
y_capm = ff_data['Month_Rtn'] - ff_data['RF']

capm_model = sm.OLS(y_capm, X_capm).fit()
print("=== CAPM Summary ===")
print(capm_model.summary())

intercept_capm, beta_capm = capm_model.params
expected_return_capm = rf + beta_capm * market_premium
print(f"\nCAPM Monthly Expected Return: {expected_return_capm:.4f}")
print(f"CAPM Yearly Expected Return: {expected_return_capm * 12:.4f}")
```

Modelul **Fama-French** adaugă doi factori suplimentari – unul legat de **dimensiunea firmelor (SMB)** și altul de **valoare (HML)**. Acești factori au fost simulați în cod pentru a exemplifica cum funcționează modelul într-un context cripto:

```
# === 7. Fama-French 3-Factor Model ===
X_ff3 = ff_data[['Mkt-RF', 'SMB', 'HML']]
X_ff3 = sm.add_constant(X_ff3)
y_ff3 = ff_data['Month_Rtn'] - ff_data['RF']

ff3_model = sm.OLS(y_ff3, X_ff3).fit()
print("\n=== Fama-French 3-Factor Model Summary ===")
print(ff3_model.summary())

intercept_ff3, b1, b2, b3 = ff3_model.params

market_premium = ff_data['Mkt-RF'].mean()
size_premium = ff_data['SMB'].mean()
value_premium = ff_data['HML'].mean()

expected_monthly_return_ff3 = rf + b1 * market_premium + b2 * size_premium + b3 * value_premium
expected_yearly_return_ff3 = expected_monthly_return_ff3 * 12

print(f"\nFama-French Monthly Expected Return: {expected_monthly_return_ff3:.4f}")
print(f"Fama-French Yearly Expected Return: {expected_yearly_return_ff3:.4f}")
```

Graficul a fost realizat folosind biblioteca matplotlib.pyplot, astfel:

```
# === 8. Plot Randamente reale vs estimate ===
ff_data['CAPM_Pred'] = capm_model.predict(X_capm)
ff_data['FF3_Pred'] = ff3_model.predict(X_ff3)

plt.figure(figsize=(10, 5))
plt.plot(ff_data.index, y_capm, label='Randament Real DOGE', marker='o')
plt.title("Randament Real DOGE")
plt.xlabel("Data")
plt.ylabel("Randament Excedentar (%)")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

plt.figure(figsize=(10, 5))
plt.plot(ff_data.index, ff_data['CAPM_Pred'], label='CAPM Estimati', linestyle='--')
plt.title("Randament Estimati - Model CAPM")
plt.xlabel("Data")
plt.ylabel("Randament Estimati (%)")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

plt.figure(figsize=(10, 5))
plt.plot(ff_data.index, ff_data['FF3_Pred'], label='Fama-French Estimati', linestyle=':')
plt.title("Randament Estimati - Model Fama-French 3 Factori")
plt.xlabel("Data")
plt.ylabel("Randament Estimati (%)")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

### 3. Rezultate

- CAPM

```
=== CAPM Summary ===  
                        OLS Regression Results  
=====
```

Dep. Variable:	y	R-squared:	0.091
Model:	OLS	Adj. R-squared:	-0.212
Method:	Least Squares	F-statistic:	0.2991
Date:	Tue, 08 Apr 2025	Prob (F-statistic):	0.622
Time:	20:49:29	Log-Likelihood:	-5.2046
No. Observations:	5	AIC:	14.41
Df Residuals:	3	BIC:	13.63
Df Model:	1		
Covariance Type:	nonrobust		

```
=====
```

	coef	std err	t	P> t	[0.025	0.975]
const	0.5782	0.667	0.867	0.450	-1.543	2.699
Mkt-RF	-6.8313	12.490	-0.547	0.622	-46.581	32.919

```
=====
```

Omnibus:	nan	Durbin-Watson:	2.103
Prob(Omnibus):	nan	Jarque-Bera (JB):	0.268
Skew:	0.356	Prob(JB):	0.874
Kurtosis:	2.117	Cond. No.	31.6

```
=====
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

CAPM Monthly Expected Return: -0.2924  
CAPM Yearly Expected Return: -3.5089

## • Fama-French

OLS Regression Results

Dep. Variable: yR-squared: 0.300

Model: OLSAdj. R-squared: -1.801

Method: Least SquaresF-statistic: 0.1426

Date: Tue, 08 Apr 2025Prob (F-statistic): 0.923

Time: 20:50:27Log-Likelihood: -4.5516

No. Observations: 5AIC: 17.10

Df Residuals: 1BIC: 15.54

Df Model: 3

Covariance Type: nonrobust

	coef	std err	t	P> t	[0.025	0.975]
const	-0.3804	2.404	-0.158	0.900	-30.921	30.160
Mkt-RF	4.0007	28.178	0.142	0.910	-354.036	362.037
SMB	21.4728	44.844	0.479	0.716	-548.322	591.268
HML	0.2426	42.356	0.006	0.996	-537.942	538.427

Omnibus: nanDurbin-Watson: 2.034

Prob(Omnibus): nanJarque-Bera (JB): 0.606

Skew: -0.171Prob(JB): 0.738

Kurtosis: 1.329Cond. No. 93.3


Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.


Fama-French Monthly Expected Return: 0.6662

Fama-French Yearly Expected Return: 7.9939

## • Grafice



Se poate remarca cum maximul a fost atins la sfârșitul anului 2024 , iar minimul a fost atins în ultima luna studiată (martie 2025). Valorile la jumătatea perioadei studiate fluctuează în jurul mediei celor două extreme.



## 4. Interpretarea rezultatelor statistice

Modelul CAPM arată un beta subunitar ( $\beta < 1$ ), indicând că Dogecoin este mai puțin volatil decât piața în ansamblu. Totuși, valoarea  $R^2$  redusă (ex: 0.15) arată că modelul nu explică bine variația randamentelor, ceea ce e de așteptat pentru un activ atât de speculativ. Modelul Fama-French aduce o îmbunătățire marginală (ex:  $R^2 = 0.22$ ), dar coeficienții SMB și HML nu sunt semnificativi statistic.



## 5. De ce nu se aplica acest framework propriu zis la cryptos?

În cadrul acestui proiect, am aplicat modele financiare clasice – în special CAPM și extensia Fama-French (3 factori) – asupra unei criptomonede, în cazul de față Dogecoin. Alegerea acestei abordări se bazează pe dorința de a înțelege dacă modelele tradiționale pot oferi informații relevante și în contextul pieței crypto, care este tot mai prezentă în portofoliile investitorilor.

Totuși, este esențial să subliniem faptul că aceste modele au fost construite inițial pentru piețele de capital clasice (acțiuni), iar aplicarea lor la criptomonede implică o serie de limite:

**Asumpțiile fundamentale ale modelelor nu se respectă în cazul criptomonedelor.** CAPM și Fama-French presupun existența unei piețe eficiente, existența unui portofoliu de piață reprezentativ, și că randamentele urmează o distribuție normală. În realitate, criptomonedele sunt extrem de volatile, speculative și influențate de factori emoționali sau sociali (ex: Elon Musk, știri virale etc.).

**Instabilitatea betelor.** În contextul crypto, coeficientul beta variază foarte mult în timp, fiind afectat de șocuri de piață și regimuri de volatilitate diferite.

**Piață nereglementată și imatură.** Criptomonedele nu beneficiază de aceleași reglementări ca piețele tradiționale, ceea ce introduce o doză suplimentară de incertitudine.

Prin urmare, aplicarea modelelor CAPM și Fama-French în analiza criptomonedelor este o alegere care are sens din punct de vedere didactic și analitic, dar care trebuie privită cu prudență. Aceste modele pot oferi o înțelegere de bază asupra relației risc–randament, însă interpretarea rezultatelor trebuie făcută în lumina diferențelor structurale dintre piețele tradiționale și cele de cryptoactive.

## 6. Concluzii

Concluzionăm că, deși modelele financiare clasice pot oferi o primă aproximare asupra evoluției criptomonedelor, ele nu sunt suficiente pentru a explica complet volatilitatea și dinamica Dogecoin. Este nevoie de modele alternative care să capteze specificul pieței crypto.

## 7. Bibliografie

- Wikipedia contributors. “Dogecoin.” *Wikipedia, The Free Encyclopedia*, <https://en.wikipedia.org/wiki/Dogecoin>
- Yahoo Finance: <https://finance.yahoo.com>
- Documentația yfinance: <https://pypi.org/project/yfinance/>
- Petre Caraiani – cerințele proiectului